# Proyecto integrador Geoprecio

## Integrantes:

Carretero Contreras Kitzia Denisse
Cintora Ruvalcaba Samuel Salvador
Hernandez Juarez Perla
Molotla Jimenez Isaac Emanuel

17/mayo/2026

—

Bases de Datos

—

Mtra. Nicole Michelle Leyva Munguia

## Base de datos

Al inicio del proyecto, se consideró utilizar la base de datos de PROFECO ('Quién es quién en los precios'). No obstante, con el objetivo de diversificar las técnicas de adquisición de datos, se optó por implementar web scraping mediante Python. Aunque esta práctica presenta desafíos éticos y técnicos, permitió recolectar información estratégica sobre los precios de la canasta básica en cuatro cadenas comerciales: Bodega Aurrera, Walmart, Soriana y La Comer.

El proceso de extracción enfrentó complicaciones críticas, particularmente el bloqueo de direcciones IP por parte de los servidores. Al detectar ráfagas de peticiones frecuentes, los sistemas de los supermercados activaron medidas defensivas que alteraron la relevancia de los resultados, devolviendo productos ajenos a las categorías objetivo —como juguetes o accesorios— en lugar de los víveres solicitados. A pesar de estas limitaciones y de la falta de herramientas de proxy de pago para mitigar los bloqueos, se logró compilar un conjunto de datos con la calidad y volumen necesarios para las metas del proyecto. Finalmente, la información fue almacenada en MongoDB y posteriormente exportada a formato CSV para su análisis y procesamiento final.

De este proceso obtuvimos la siguiente tabla:

| | A | B | C | D | E | F | G | H | I |
|---|---|---|---|---|---|---|---|---|---|
| 1 | _id | url | fecha_actualizacion | nombre | precio | tienda | categoria | precio_num | |
| 2 | 69e67f8aff0051c2a41a1823 | https://www.walmart.com | 2026-04-27T19:06:33.934Z | Leche Alpura clÃ¡sica caja | $170.00 | Walmart | Otros / Sin Clasificar | 170 | |
| 3 | 69e67f92ff0051c2a41a1824 | https://www.walmart.com | 2026-04-27T19:06:33.945Z | Leche Santa Clara deslacto | $180.00 | Walmart | Otros / Sin Clasificar | 180 | |
| 4 | 69e67f9bff0051c2a41a1825 | https://www.walmart.com | 2026-04-27T19:06:33.940Z | Leche Lala fresca deslactos | $175.00 | Walmart | lacteos | 175 | |
| 5 | 69e67fa4ff0051c2a41a1826 | https://www.walmart.com | 2026-04-27T19:06:33.932Z | Leche Alpura deslactosada | $172.00 | Walmart | Otros / Sin Clasificar | 172 | |
| 6 | 69e67fabff0051c2a41a1827 | https://www.walmart.com | 2026-04-27T19:06:33.943Z | Leche Lala UHT entera 6 pa | $172.00 | Walmart | Otros / Sin Clasificar | 172 | |
| 7 | 69e7a7a4ff0051c2a41a1828 | https://www.walmart.com | 2026-04-27T19:06:33.095Z | Frijoles bayos La CosteÃ±a | $13.00 | Walmart | Otros / Sin Clasificar | 13 | |
| 8 | 69e7a7acff0051c2a41a1829 | https://www.walmart.com | 2026-04-27T19:06:33.105Z | Frijoles bayos Isadora refri | $22.00 | Walmart | Otros / Sin Clasificar | 22 | |

## Descripción:

- **_id** (varchar): Identificador único generado automáticamente para garantizar la integridad y distinción de cada registro en la base de datos.
- **url** (varchar): Enlace específico del producto; se utilizó como parámetro de control para evitar la duplicidad de información durante el proceso de extracción
- **Fecha_actualizacion** (datetime): Registro temporal que permite mantener la consistencia cronológica sobre el momento exacto en que se capturó la información de cada tienda.
- **Nombre** (varchar): Denominación comercial del producto para su identificación y referencia.
- Precio (varchar): Valor total del producto capturado en su formato original de texto al momento de la obtención.
- **Tienda** (varchar): Nombre del establecimiento o cadena comercial de donde se extrajeron los datos.
- **Categoría** (varchar): Etiqueta de clasificación diseñada para agrupar productos similares entre las distintas tiendas y facilitar su comparación.
- **Precio_num** (decimal): Representación numérica del precio tras un proceso de limpieza y conversión, habilitando la ejecución de operaciones aritméticas y análisis estadísticos.

## Diagrama de flujo de datos:

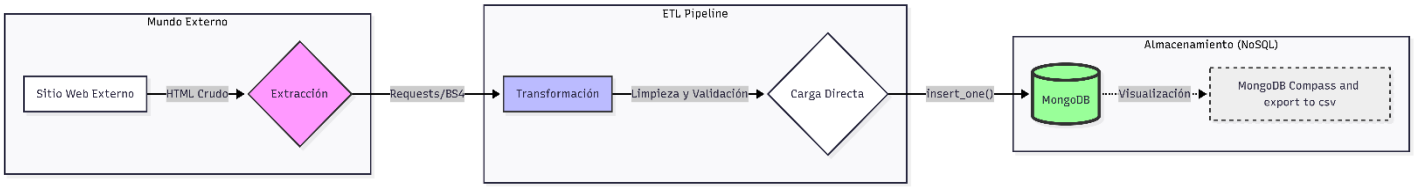


Descripción del Flujo de Datos (Pipeline ETL)

El proceso de gestión de información para el análisis de precios se divide en tres fases principales, diseñadas para transformar datos no estructurados de la web en información útil para el análisis estadístico:

1. Fase de Extracción (Mundo Externo)

El flujo comienza en el Mundo Externo, donde se interactúa directamente con los sitios web de los supermercados. A través de peticiones automatizadas, se obtiene el HTML crudo de las páginas de productos. Este contenido pasa por un proceso de Extracción (utilizando librerías como BeautifulSoup o Selenium en Python), donde se filtran los elementos específicos (Requests/BS4) necesarios para construir los registros de la base de datos.

2. Pipeline de Procesamiento (ETL Pipeline)

Una vez extraídos los datos, ingresan al ETL Pipeline (Extract, Transform, Load), que actúa como el motor lógico del proyecto:

- Transformación: En esta etapa, el texto crudo se estructura según los campos definidos (Nombre, Tienda, Categoría, etc.).
- Limpieza y Validación: Aquí se realiza la conversión técnica, como transformar el precio de formato texto a decimal (Precio_num) y validar que la información sea consistente y libre de errores antes de su almacenamiento.
- Carga Directa: Una vez que el dato es validado, se prepara para su inserción final en el ecosistema de almacenamiento.

3. Almacenamiento y Salida (NoSQL)

La fase final ocurre en el entorno de Almacenamiento (NoSQL):

- Persistencia en MongoDB: Utilizando el comando insert_one(), los datos procesados se guardan de forma permanente en MongoDB.
- Visualización y Exportación: A través de MongoDB Compass, se supervisa la integridad de los datos para finalmente realizar una exportación a formato CSV. Este archivo final es el que permite realizar el análisis de datos posterior y la comparación de precios entre las distintas cadenas comerciales.

Esta estructura de flujo garantiza que, a pesar de los desafíos técnicos mencionados anteriormente (como bloqueos de IP), los datos que finalmente llegan al análisis sean de alta calidad, confiables, estén correctamente normalizados y de alta utilidad para la finalidad del proyecto.

## Conclusión

La arquitectura de almacenamiento y el flujo de datos (como el diseñado en este proyecto) no son meros pasos administrativos, sino el cimiento sobre el cual se construye cualquier sistema inteligente. En el contexto de la Inteligencia Artificial, la calidad y disponibilidad de los datos determinan directamente la capacidad predictiva y la precisión de los modelos; sin una persistencia de datos robusta, organizada y limpia, incluso los algoritmos de Machine Learning más avanzados carecerían de la materia prima necesaria para generar conocimiento útil. Como se observó en la implementación de GeoPrecio, contar con una base de datos NoSQL permitió no solo capturar información heterogénea de diversas fuentes, sino también garantizar que dicha información fuera íntegra y estuviera lista para su análisis estadístico.

Asimismo, la importancia de materias enfocadas en el manejo de datos para la carrera de Ciencia de Datos e IA es fundamental. Esta disciplina nos enseña a:

- Gestionar el ciclo de vida del dato: Desde la extracción mediante técnicas de web scraping hasta la persistencia y exportación para análisis final.
- Resolver problemas de ingeniería: Implementar soluciones ante desafíos técnicos reales, como el filtrado de direcciones IP o la normalización de formatos inconsistentes.
- Asegurar la escalabilidad: Diseñar estructuras de datos que permitan el crecimiento de proyectos complejos sin perder la consistencia lógica.

Finalmente, el dominio de las bases de datos y los procesos ETL nos proporciona la autonomía para recolectar nuestro propio conjunto de datos, permitiéndonos transformar el "ruido" del mundo externo en activos digitales estratégicos para la toma de decisiones.

**Referencias:**

https://www.bodegaaurrera.com.mx/

https://www.lacomer.com.mx/

https://www.soriana.com/

https://www.walmart.com.mx/

https://gemini.google.com/app/

Se hizo uso de IA para mejorar la redacción del texto.

Repositorio del proyecto: